



Zouhair DKHISSI

AI Engineer – LLM & NLP

📞 07 82 04 27 41 ✉ dkhissizouhair5@gmail.com 🌐 zouhair05.netlify.app
🔗 Zouhair055 📄 zouhair-dkhissi 📄 Permis B

Profil

Ingénieur IA spécialisé en LLM, NLP et automatisation, avec une expérience en conception et déploiement de solutions IA en environnement professionnel.

Compétences techniques

- **IA, LLM & Agents** : RAG (Retrieval-Augmented Generation), LLMs (Claude 3.7 Sonnet, GPT-4o / O3-mini, DeepSeek-R1, Llama 3.3, Mistral), OpenAI API, Groq API, LangChain, Sentence Transformers, BERT (Re-ranking), NLP (SpaCy, NLTK)
- **Bases de données & Vectorielles** : ChromaDB (Base vectorielle), MongoDB (NoSQL), SQL, Redis
- **Backend, Cloud & Déploiement** : Python (FastAPI), Node.js (Express), API REST, Docker, Git
- **Frontend, Mobile & Outillage** : React, Angular, Flutter, Android (Kotlin / Java), VBA (Plugins Microsoft Outlook), PyPDF2, Openpyxl, Postman

Expériences professionnelles

All Energies

Consultant IA – Automatisation & Déploiement Hybride

Monaco

2025 – 2026

- **Automatisation de la trésorerie (LLM & Data)** : Implémentation d'une solution d'IA pour remplir automatiquement des fichiers Excel financiers complexes. Test de modèles Open Source locaux (Mistral, Llama 3 8B) et intégration de l'API Groq (Llama 3 70B) pour contourner les limites matérielles locales (RAM/GPU).
- **Création d'un workflow d'IA pour documents (Signature PDF)** : Design et développement de A à Z d'un système intelligent de signature de PDF (Node.js, PDF-lib) couplé à un plugin Outlook (VBA). Utilisation du LLM pour analyser la mise en page et détecter la meilleure zone de signature.
- **Architecture Hybride** : Déploiement initial de l'API dans le Cloud (Render). Face aux contraintes de production (Cold start, latence), migration vers une solution locale autonome (packagée en .exe) pour garantir la réactivité (MCO) et la stricte confidentialité des données.
- **Contraintes matérielles et Hardware** : Évaluation de modèles Open Source locaux (Mistral-7B, Llama-3-8B en GGUF) face aux contraintes d'infrastructure (limites RAM/GPU), orientant les choix d'architecture technique.

ProBTP

Ingénieur IA/LLM (RAG / NLP)

Sophia Antipolis

2024 – 2025

- **Système RAG On-Premise** : Architecture Python/LangChain pour documents hétérogènes (PDF, Excel, Word via PyWin32/PyPDF2) avec embeddings locaux (all-mpnet-base-v2), re-ranking BERT et ChromaDB garantissant la confidentialité des données.
- **API FastAPI & Optimisation Coûts** : Orchestration d'OpenAI API et gestion dynamique de l'historique conversationnel (MongoDB) avec résumé automatique de contexte pour réduire la consommation de tokens.
- **Data Processing & DevOps** : Stratégies de chunking dynamique (taille/page), prétraitement NLTK et conteneurisation Docker de bout en bout pour le déploiement client et le MCO.

Agiir Network

Assistant Chef de Projet WordPress

Roanne

2023

- Installation et configuration de WordPress sur serveur Virtualmin.
- Gestion des accès, permissions et rédaction de spécifications techniques.
- Sélection et intégration de plugins adaptés aux besoins fonctionnels du client.
- Suivi technique du projet en lien avec les besoins des équipes internes.

Projets

Université Côte d'Azur	
<i>Application mobile IA – Prise de notes intelligente</i>	2025
— Développement d'une application Android (Kotlin / Java) intégrant l'IA OpenAI. — Résumés automatiques et extraction de tags via OpenAI. — Stockage local optimisé avec Room Database.	
Université Côte d'Azur	
<i>Chatbot IA – Urgences médicales</i>	2025
— Conception d'un chatbot médical contextuel capable d'analyser et classer des documents médicaux. — Backend en Python (FastAPI) avec gestion des sessions et des données patients. — Intégration de LangChain pour la mémoire conversationnelle et la contextualisation des réponses. — Utilisation de NLP (SpaCy, TLN bas niveau) pour l'extraction d'entités nommées.	
Université Côte d'Azur	
<i>Application Web de Gestion des Devoirs (MEAN Stack)</i>	2024
— Développement d'une application web full-stack pour la gestion des devoirs via une interface dynamique. — Mise en œuvre complète des opérations CRUD avec Angular, Node.js, Express.js et MongoDB. — Conception d'API REST pour assurer la communication frontend/backend. — Déploiement de l'application sur des plateformes modernes telles que Netlify et Render.	
Université Côte d'Azur	
<i>Classification d'images – Vêtements</i>	2024
— Développement d'une application e-commerce mobile avec Flutter (Dart). — Utilisation de Firebase pour l'authentification des utilisateurs et la gestion des données. — Implémentation d'un modèle de classification CNN (TensorFlow Lite) pour la prédiction des catégories.	
Université Côte d'Azur	
<i>Assistant vocal IA – Jeu vidéo</i>	2024
— Conception d'un assistant vocal intelligent permettant de contrôler un jeu par la voix. — Intégration de la reconnaissance vocale via Whisper API et génération de réponses vocales (TTS). — Exploitation de ChatGPT avec Function Calling pour interpréter et exécuter des commandes complexes.	

Formation

Université Côte d'Azur	Nice
<i>Master MIAE – Spécialisation Intelligence Artificielle</i>	2024–2025
Université Côte d'Azur	Nice
<i>Master MIAE – Méthodes Informatiques Appliquées à la Gestion</i>	2023–2024
Université Jean Monnet, Saint-Étienne	Roanne
<i>Licence Traitement de l'Information et Instrumentation</i>	2022–2023

Langues

- Français : courant
- Anglais : professionnel

Qualités & Centres d'intérêt

Esprit d'équipe & Stratégie (Jeux de stratégie en ligne / Esport) – **Organisation & Cohésion** (Randonnées régulières, Calanques dans la région) – **Rigueur** (Natation et marche) – **Patience & Observation** (Pêche) – **Créativité** (Photographie)